樹脂粘度モデル開発　手順 3c の学習結果の説明

最終候補のモデルを MCMC で推定：用語集とグラフの見方（機械学習・統計を初めて学ぶ人向け）

2026 年 10 月 13 日

目次

1　この文書について ・・・

個)。最尤推定と比べて、何が変わるかを調べました。

▷**読み方**：2 章で何をしたかをつかみ、分からない言葉は 3 章の用語集で調べてください。4 章で図の見方、5 章で表の見方、6 章で結果のまとめを説明します。

▷**数値について**：文中の数値は、この文書を作った時点の results の表から取り出したものです。

▷**元のノート**：01_機械学習コードフォルダ の 手順 3c_最終候補の MCMC.ipynb です。ノートの先頭に使い方があり、「設定エリア」だけを直せば設定を変えられます。サンプリングには、全体で約 46 分かかります（保存済みのサンプルがあれば、それを読み込んで省けます)。報告書・発表資料用の高解像度のグラフ（せん断速度 — 粘度）は、ノート 9 章のセルで作ります（4 章の最後)。

▷**記号表**：記号・モデル名（B0T、R3、R2 など)・列名の一覧は、学習結果説明_記号表.pdf にあります。

▷**作り直し方**：results フォルダで lualatex 学習結果説明_手順 3c.tex を 2 回実行すると、この PDF を作り直せます。

2 何をしたか（概要）

2.1 目的

手順 3b までは、ハイパーパラメータ（振幅・長さスケール・ノイズ分散など）を、データが最も「ありそう」になる 1 組の値（**最尤推定**）に決めていました。1 組だけを使うと、次の 2 つの心配があります。

▷**心配 1：最適化が、悪い所で止まる**：最適化は、近くの「谷」で止まることがあります。手順 3b で、PP の S_T の B0T がそうでした（T_{set} の長さスケールが下限に張り付き、210 ℃ を内挿できませんでした)。

▷**心配 2：ハイパーパラメータの不確かさを無視している**：データが少ないと、ハイパーパラメータは 1 つの値に決まりきりません。1 組だけで予測すると、予測の幅が狭すぎるかもしれません。

MCMC（マルコフ連鎖モンテカルロ法）は、ハイパーパラメータを 1 組に決めず、「ありそうな値の分布（事後分布)」を求める方法です。予測は、その分布からたくさん取り出した値で予測した結果を、混ぜて出します。これで 2 つの心配を調べます。手順 5 の本実装に使う形のモデルだけを、ここで MCMC にかけます（CLAUDE.md §5：最終候補だけ MCMC)。

2.2　候補のモデルと、分け方

表 1　最終候補のモデル（ARD Matern 5/2 ＋ 線形カーネル ＋ ノイズ。入力は ln をとった値で、T_{set} は ℃）

記号	入力	選んだ理由
B0T	ショットごとの $\dot{\gamma}$，H，T_{set}	手順 3b で、PP の S_T で最適化が失敗したモデル。MCMC で直るかを見る。
R3	条件平均の $\dot{\gamma}$，H，T_{set}	手順 3b の結論で、基本とするモデル。
R2	射出速度 v，H，T_{set}	設定値だけで予測できるか（実測の $\dot{\gamma}$ を使わない）。

T_{ff} や P3_2 を足したモデルは、手順 3b で要らないと分かったので、入れていません。分け方は、S_V（5data で学習して 3data で検証）と、S_T（190・230 ℃ で学習して 210 ℃ を予測。3data の 210 ℃ は S_T3）です。材料は PP と粉砕材混合 PP の 2 つなので、モデル 3 × 分け方 2 × 材料 2 ＝ 12 組です。

2.3　MCMC の方法（手順 2 と同じ、自作の適応型メトロポリス法）

1. 今いる値（ハイパーパラメータの組）の近くに、ランダムに候補を出す。
2. 候補のほうが「ありそう」（対数周辺尤度が大きい）なら、そこへ移る。そうでなくても、確率的に移ることがある。移らなければ、その場にとどまる。
3. これを何千回も繰り返すと、「ありそうな値」を、ありそうな度合いに比例した頻度で訪れる。その足跡が、事後分布。
4. 最初の 3,000 回（**調整期間**）は、足跡から、候補の出し方（ばらつきの大きさ・向き）を学び、採択率が 0.234 に近づくよう合わせる。この期間の足跡は捨てる。
5. 本番は 8,000 回。チェーン（別々の出発点から歩く足跡）は 4 本。収束していなければ（R-hat が 1.01 を超える、または有効サンプル数が 400 に届かない）、本番を 20,000 回に増やして、やり直す。

事前分布は、カーネルの探索範囲（振幅 10^{-3}〜10^{3}、長さスケール 10^{-2}〜10^{2}、線形項の振幅と σ_0、ノイズ分散 10^{-6}〜10）の中で、対数をとって一様です。範囲の中では、事後分布は尤度に比例するので、最も高い所は、最尤推定と一致します。

予測は、事後サンプルを等間隔に 200 個選び、それぞれのハイパーパラメータで GPR を作って予測し（ノイズ込みの正規分布）、200 個の分布を等しい重みで混ぜた「混合分布」で行います。

3　用語集

3.1　MCMC に関する用語

・**事後分布**：データを見たあとの、「ハイパーパラメータが、どの値でありそうか」の分布。山の中心がありそうな値、山の幅が不確かさです。最尤推定は、この山の頂上の 1 点にあたります。

・**事前分布**：データを見る前の、「どの値でありそうか」の分布。ここでは、探索範囲の中で、対数をとって一様（どの桁も同じ重み）にしました。

・**マルコフ連鎖・チェーン**：今の値だけから、次の値が決まる、値の列。MCMC では、この列（足跡）を「チェーン」と呼び、別々の出発点から 4 本歩かせます。

・**調整期間（ウォームアップ）**：出発点の影響を消し、候補の出し方を学ぶ最初の期間。サンプルとしては使いません（3,000 回）。

・**採択率**：候補に移れた割合。小さすぎると足跡が動かず、大きすぎると小さな歩幅しか出ていません。0.234 前後が、目安です。

・**R-hat（アールハット）**：4 本のチェーンの足跡が、同じ分布に収まっているかの目安。1.00 に近いほど、一致しています。1.01 以下が目標です。

・**有効サンプル数（ESS）**：足跡は、前後で似ているので、「独立なサンプル何個分の情報があるか」を表す数。400 以上が目標です。値が小さいと、分布が粗くしか分かりません。

・**トレース図**：チェーンの値を、反復の順に描いた図。同じ範囲を上下して、4 本が混ざっていれば、収束しています。

・**多峰性（複数の山）**：事後分布に、離れた山が複数あること。チェーンは、山の間を行き来しにくく、R-hat が大きくなります。

・**混合分布**：たくさんの正規分布を、等しい重みで混ぜた分布。ここでは、事後サンプルごとの予測分布を混ぜたもの。ハイパーパラメータの不確かさを、予測の幅に入れられます。

・**最尤推定と MCMC**：最尤推定は、尤度が最大の 1 点。MCMC は、尤度に比例した分布全体。山が 1 つで尖っていれば、同じ結果になります。

3.2　評価と、ハイパーパラメータに関する用語

・**RMSE・被覆率・NLPD**：手順 3a・3b の用語集と同じです。RMSE は予測の平均的な誤差（$\ln \eta$）、被覆率は 95% 予測区間に実測が入った割合、NLPD は予測の当たり具合と区間の適切さをまとめた指標（小さいほど良い）です。MCMC では、混合分布の平均・累積分布・密度で計算します。

・**長さスケール**：入力がどれだけ変わると出力が大きく変わるかの目安（標準化した入力に対する値）。探索範囲は 10^{-2}〜10^{2}。上限に近いと、その入力はほとんど使われていません。

・**線形カーネルの σ_0 と振幅**：線形カーネル（$\sigma_0^2 + x \cdot x'$ に振幅の 2 乗を掛けたもの）のパラメー

タ。目的変数を中心化し、入力を標準化しているので、定数の項（σ_0）は、データでほとんど決まらず、事後分布が探索範囲いっぱいに広がります（予測にはほとんど効きません）。

・**感度確認**：手順 3b の用語集と同じです。

4　図の見方

図ごとに、「何を示す図か」「軸と記号」「見るポイント」「今回の結果」の順に説明します。図のファイルは `results/step3c_mcmc/` にあります。

4.1　トレース図（`fig\_trace\_*.png`）

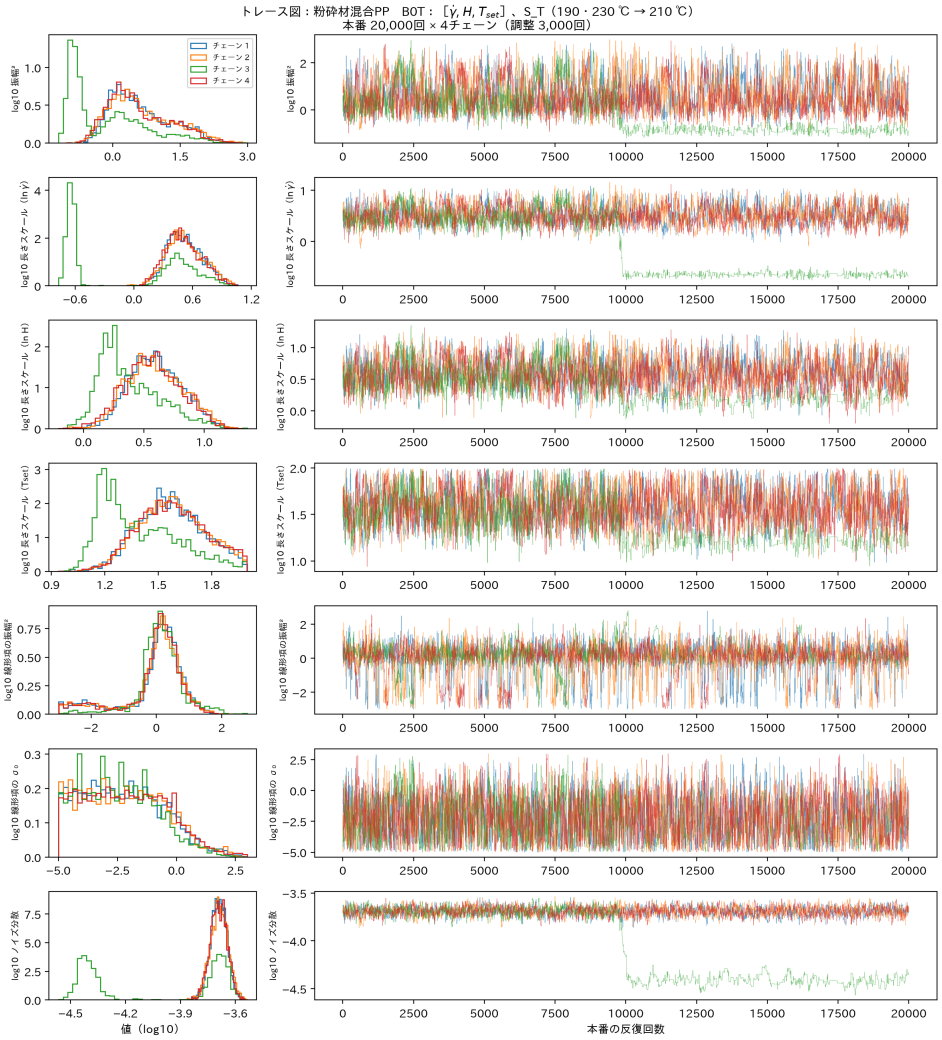


図 1　粉砕材混合 PP の B0T（S_T の学習）のトレース図。チェーン 3 が、10,000 回ごろに別の山へ移っている

▷**ファイル**：`results/step3c_mcmc/fig_trace_S_V_PP_B0T.png` のように、分割・材料・モデルごとに 1 枚（12 枚）。

▷**何を示す図か**：チェーンが、ちゃんと同じ分布を歩いているか（収束）を確かめる図です。ハイパーパラメータ 1 つにつき、1 行です。

▷**軸と記号**:左は、チェーンごとの分布（ヒストグラム）、右は、本番の反復ごとの値（足跡）。値は、$\log_{10}$（常用対数）。4 色がチェーン 1〜4。上から、振幅の 2 乗、各入力の長さスケール、線形項の振幅の 2 乗、線形項の σ_0、ノイズ分散。

▷**見るポイント**：右の足跡で、4 色が混ざり合って、同じ範囲を上下しているか。左の分布で、4 色が重なっているか。1 色だけ離れていれば、収束していません。

▷**今回の結果**：12 組のうち 11 組は、4 本のチェーンが混ざり合い、R-hat が 1.01 以下、ESS が 400 以上になりました（表 2)。最初の 8,000 回で ESS が足りなかった 4 組は、本番を 20,000 回に増やしました。収束の目安を満たさなかったのは、粉砕材混合 PP の B0T（S_T の学習）の 1 組です。図のように、チェーン 3 が 10,000 回ごろに別の山（ノイズ分散が小さく、$\dot{\gamma}$ の長さスケールが短い解）へ移り、R-hat が 1.31、ESS が 10 になりました。B0T の事後分布には、「ショットごとの $\dot{\gamma}$ に細かく合わせる山」と「なめらかな山」があり、チェーンが行き来しにくいためです（多峰性)。この組の予測は、4 本をすべて混ぜて計算しているので、参考値として読みます。

4.2　事後分布と最尤推定値（fig_posterior_vs_mle_*.png）

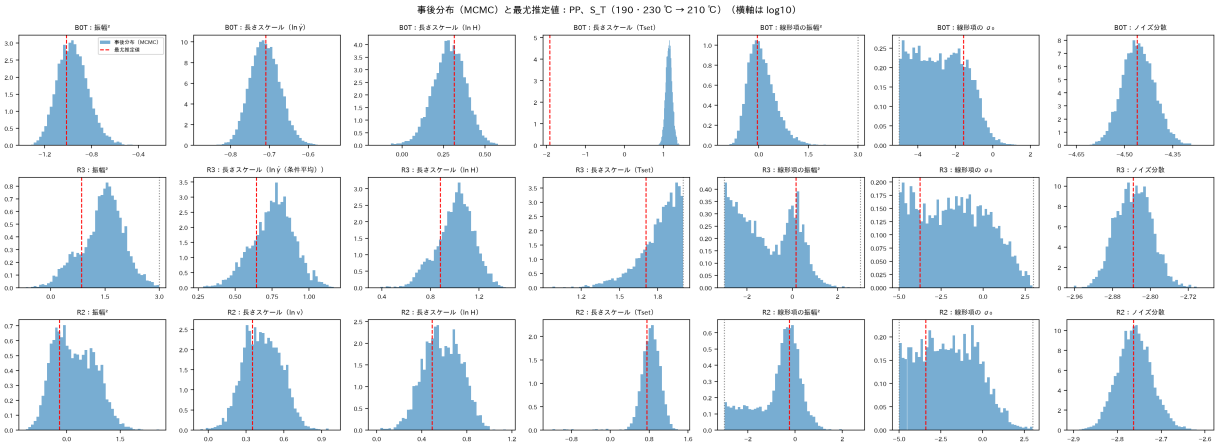


図 2　PP（S_T の学習）：事後分布（青）と最尤推定値（赤い破線）。灰色の点線は事前分布の範囲の端

▷**ファイル**： fig_posterior_vs_mle_S_V_PP.png、 fig_posterior_vs_mle_S_T_PP.png、fig_posterior_vs_mle_S_V_MIX.png、fig_posterior_vs_mle_S_T_MIX.png（材料と分け方ごとに 1 枚)。

▷**何を示す図か**：ハイパーパラメータの事後分布（山の形）と、最尤推定の値を比べる図です。行がモデル（B0T・R3・R2)、列がハイパーパラメータです。

▷**軸と記号**：横軸は値（$\log_{10}$)、青い棒が事後分布、赤い破線が最尤推定値、灰色の点線が、事前分布の範囲の端。

▷**見るポイント**：(1) 赤い破線が、青い山の中にあるか（最尤推定が、分布の中心付近か）。(2) 山が範囲の端（灰色の点線）に当たっていないか（端に当たれば、そのパラメータは、データだけでは決まらない）。

▷**今回の結果**：PP の B0T（S_T の学習）では、T_{set} の長さスケールの最尤推定値が 0.012 で、事後分布の山（中央値 13.8、95% 区間 9.5〜20.3）から大きく離れています（表 4）。最尤推定は、確率のほとんどない谷に止まっていました。MCMC は、山の本体（長さスケール 約 14）を見つけます。R3 では、T_{set} の長さスケールの山が、上限（100）の近くにあります（中央値 約 70〜76）。T_{set} の効果が、Matern の部分ではなく、線形カーネルの部分で、ほぼ直線的に表されていることを意味します。事前分布の範囲の端に届いた R3 の 4 組は、この理由です。線形項の σ_0（右から 2 番目の列）は、範囲いっぱいに広がっていて、データでは決まりません（予測には、ほとんど効きません）。ほかのハイパーパラメータは、最尤推定の値が、山の中にあります。

4.3 図 A：最尤推定と MCMC の比較

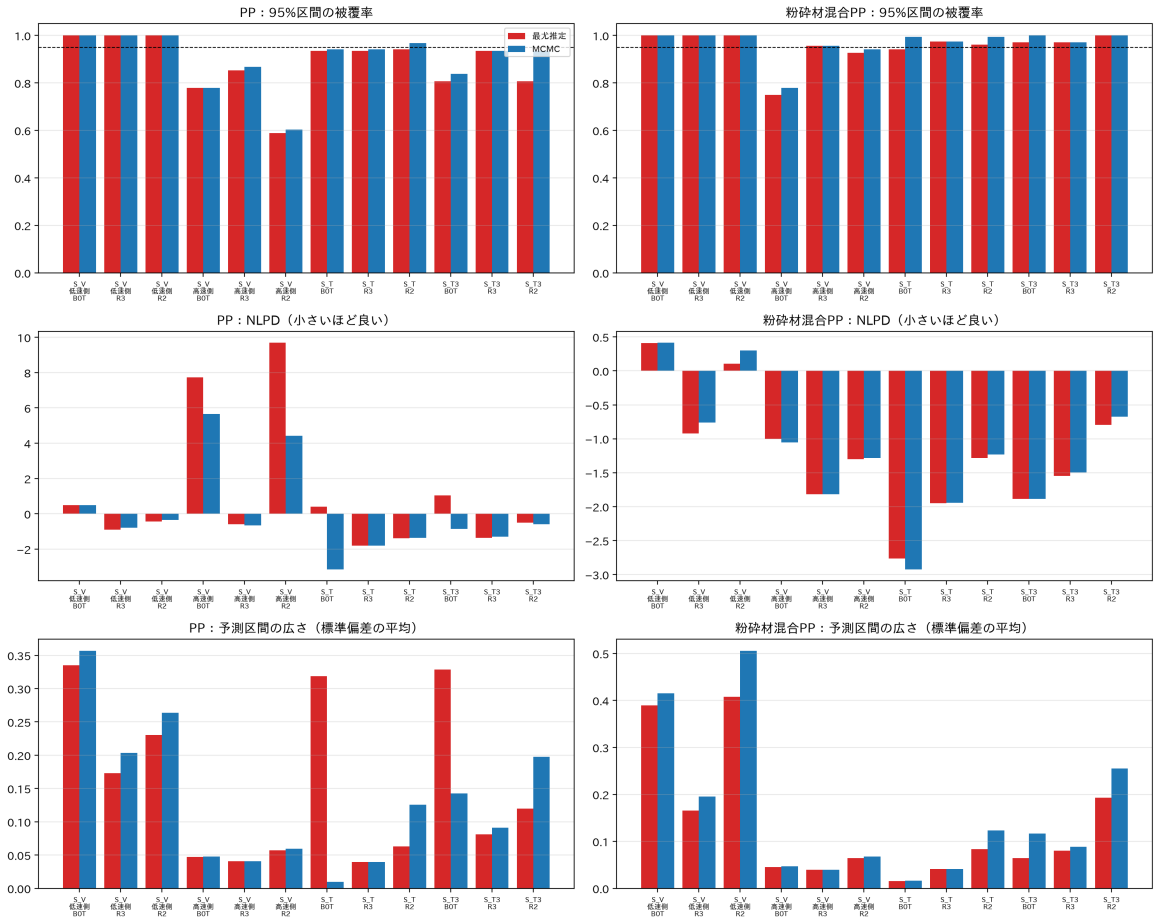


図 3　被覆率・NLPD・予測区間の広さの比較（赤：最尤推定、青：MCMC）

▷**ファイル**：`results/step3c_mcmc/figA_mle_vs_mcmc.png`

▷**何を示す図か**：同じモデル・同じ検証データで、最尤推定と MCMC の予測を比べた図です。左が PP、右が粉砕材混合 PP。上段が 95% 区間の被覆率、中段が NLPD、下段が予測区間の広さ（予測標準偏差の平均）。

▷**軸と記号**：横軸は、検証の種類（S_V の低速側・高速側、S_T、S_T3）とモデル。赤い棒が最尤推定、青い棒が MCMC。被覆率の黒い破線は 0.95。

▷**見るポイント**：赤と青の棒が、ほぼ同じ高さなら、最尤推定で十分。青が低い NLPD なら、MCMC のほうが良い。区間の広さは、青が高ければ、ハイパーパラメータの不確かさが、予測の幅に入っています。

▷**今回の結果**：**R3**：高速側・S_T は、最尤推定とほとんど同じです（NLPD の差 0.1 未満）。低速側（外挿）では、MCMC のほうが区間が約 1.2 倍広く（保守的）、NLPD が +0.11（PP）・+0.16（粉砕材混合 PP）と少し悪くなります。RMSE も、PP で 0.064 から 0.079、粉砕材混合 PP で 0.051 から 0.101 と、わずかに大きくなります。事後の平均は、直線的な傾きの不確かさ（線形項）を平均するため、低速側で、最尤推定よりやや外れやすくなるためです。最尤推定でも十分な精度です。**B0T**：PP の S_T では、最尤推定が谷に止まっていたため、MCMC で RMSE が 0.362 から 0.010、NLPD が 0.41 から −3.15 へ、大きく改善します（区間の広さは 0.319 から 0.010）。**R2**：MCMC の区間は、S_T で約 1.5〜2 倍と広くなり、PP の S_V の高速側の NLPD は 9.70 から 4.42 へ改善します（P03 に引きずられる最尤推定より、広めの区間のため）。

4.4 図 B：設定温度の効果の事後分布

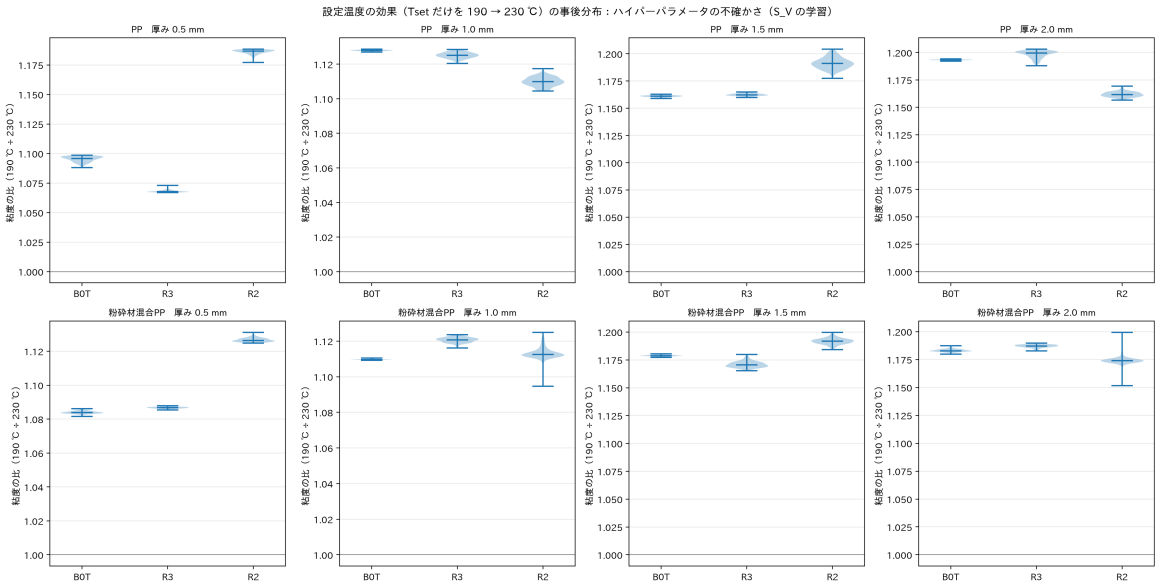


図 4　Tset だけを 190 → 230 ℃ にした予測の粘度比の分布（ハイパーパラメータの不確かさによる）

▷**ファイル**：`results/step3c_mcmc/figB_tset_effect_posterior.png`

▷**何を示す図か**：190 ℃ の粘度が 230 ℃ の何倍になるかの予測が、ハイパーパラメータの不確かさで、どれだけ変わるかを見る図です。

▷**軸と記号**：横軸がモデル、縦軸が粘度の比。バイオリンの形が、事後サンプルごとの比の分布。横線が、最小・中央値・最大。パネルは、厚みごと（上段 PP、下段 粉砕材混合 PP）。

▷**見るポイント**：形が細ければ、ハイパーパラメータが違っても、温度の効果は同じ。1 より上にあれば、190 ℃ のほうが粘い。

▷**今回の結果**：B0T と R3 の分布は、非常に細く、95% 区間の幅が最大でも PP で 0.012、粉砕材混合 PP で 0.011 です。ハイパーパラメータの不確かさは、設定温度の効果（比 1.07〜1.20）にほとんど影響しません。R2 は、少し幅が広くなります（最大 0.019）。どのモデル・厚みでも、事後サンプルの 95% 以上で、190 ℃ のほうが 230 ℃ より粘い（最小 1.00）という結果です。なお、この図は「ハイパーパラメータの不確かさ」だけを表します。予測そのものの不確かさ（予測区間）は、図 C で見ます。

4.5　図 C：設定温度ごとの予測曲線（R3・B0T）

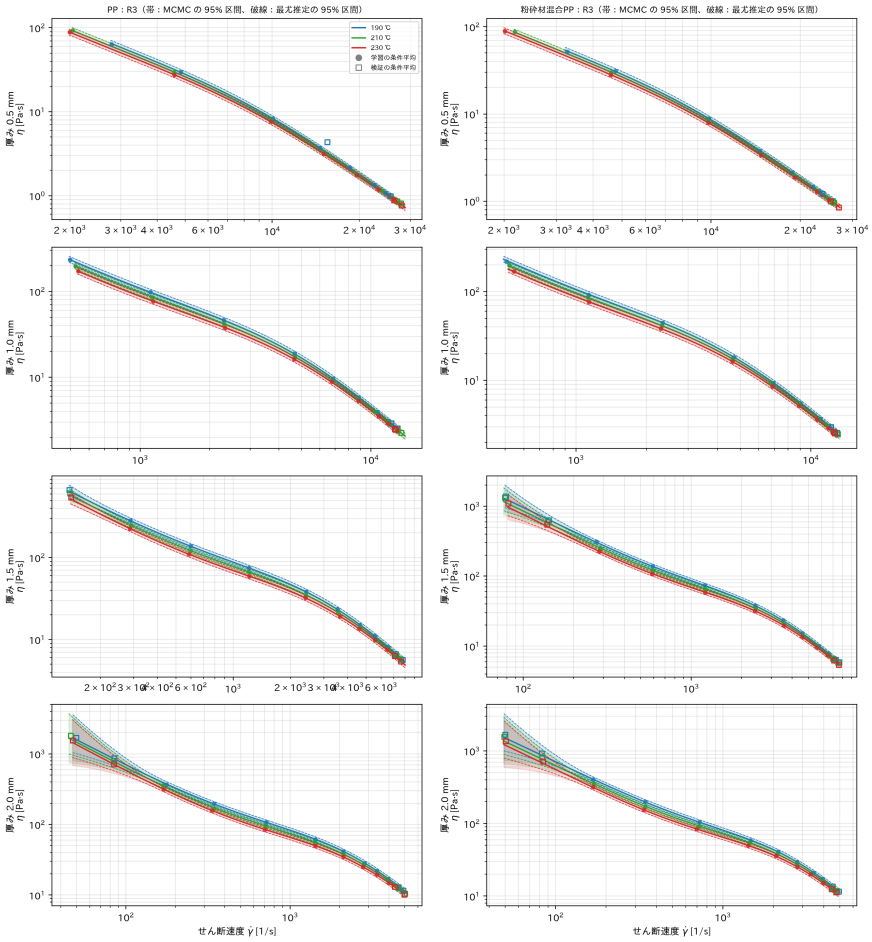


図 5　R3：設定温度ごとの予測曲線。帯は MCMC の 95% 区間、破線は最尤推定の 95% 区間

▷**ファイル**：`results/step3c_mcmc/figC_R3_curves.png`（R3）、`figC_B0T_curves.png`（B0T）

▷**何を示す図か**：5data で学習したモデルの、設定温度ごとの予測曲線を、MCMC の区間（帯）と最尤推定の区間（破線）で比べた図です。左が PP、右が粉砕材混合 PP、行が厚み。

▷**軸と記号**：横軸が $\dot{\gamma}$ [1/s]、縦軸が η [Pa·s]（対数軸）。色が設定温度（青 190 ℃、緑 210 ℃、赤 230 ℃）。丸が学習の条件平均、白抜きの四角が検証の条件平均。

▷**見るポイント**：帯と破線が、どれだけ違うか。検証の四角が、帯に入っているか。

▷**今回の結果**：R3 では、MCMC の帯（青・緑・赤）と最尤推定の破線が、ほとんど重なります。低速側（左端）では、帯が破線より少し広がります。検証の四角（外挿）は、帯の中に入ります。B0T は、曲線が波打ち、帯の幅も場所で変わります（ショットごとの $\dot{\gamma}$ を入力にしているため。手順 3b の図 1 と同じ）。

4.6 高解像度のグラフ（報告書・発表資料用）

▷**ファイル**：`results/step3c_mcmc/highres/hr_<材料>_<モデル>_<学習>_mcmc_by-thickness_<厚み>mm.png`（厚みごと）と、`..._by-temperature_<温度>C.png`（設定温度ごと）。Git には入れません（ノートのセルで、いつでも作り直せます）。

▷**何を示す図か**：GPR6 月のノートのセル 9-2 と同じ見せ方の、せん断速度 — 粘度の学習結果グラフを、**600 dpi（15 × 10 インチ）**で 1 枚ずつ保存します。MCMC の事後サンプル 200 個の予測を混ぜた分布で描き、線は予測の平均、帯は 95% 予測区間、塗りつぶしの点は学習の条件、白抜きの点は検証の条件、黒い × は「感度確認」の条件です。既定は、R3（5data で学習）です。

▷**変え方**：ノート 9 章の「高解像度のグラフ」のセルの先頭に、設定エリアがあります（描くモデル・材料・学習の種類、レイアウト、帯、点、軸の範囲、図の大きさ・解像度、文字の大きさ、保存形式など）。**そのセルの設定だけを直して、そのセルだけを実行し直せます**（サンプリングはやり直しません。ノート全体を一度実行した後で）。

5　表の見方

表 2　サンプラーの統計（sampler_stats.csv）。R-hat は最大、ESS は最小。採択率は 0.19〜0.28

材料	分割	モデル	本番の回数	R-hat	ESS(bulk)	ESS(tail)	端に届いた
PP	S_V	B0T	8,000	1.007	911	917	0
PP	S_V	R3	20,000	1.008	1225	1492	1
PP	S_V	R2	20,000	1.004	1605	1063	0
PP	S_T	B0T	20,000	1.005	1542	2876	0
PP	S_T	R3	8,000	1.008	440	411	1
PP	S_T	R2	8,000	1.006	480	535	0
粉砕材混合 PP	S_V	B0T	8,000	1.009	936	1477	0
粉砕材混合 PP	S_V	R3	8,000	1.007	552	951	1
粉砕材混合 PP	S_V	R2	8,000	1.009	834	888	0
粉砕材混合 PP	S_T	B0T	20,000	1.315	10	5	0
粉砕材混合 PP	S_T	R3	8,000	1.006	635	1040	1
粉砕材混合 PP	S_T	R2	8,000	1.008	799	1083	0

表 3　最尤推定と MCMC の比較（検証データ。RMSE ／ NLPD ／区間の広さ（予測標準偏差の平均）。mle_vs_mcmc.csv）

			RMSE		NLPD		区間の広さ	
材料	検証	モデル	最尤	MCMC	最尤	MCMC	最尤	MCMC
PP	S_V 低速	B0T	0.474	0.469	0.50	0.48	0.335	0.357
		R3	0.064	0.079	−0.90	−0.79	0.173	0.203
		R2	0.161	0.197	−0.43	−0.35	0.231	0.264
	S_V 高速	B0T	0.060	0.060	7.74	5.66	0.047	0.048
		R3	0.074	0.074	−0.59	−0.66	0.041	0.041
		R2	0.320	0.320	9.70	4.42	0.057	0.060
	S_T	B0T	0.362	0.010	0.41	−3.15	0.319	0.010
		R3	0.039	0.039	−1.82	−1.82	0.039	0.040
		R2	0.060	0.061	−1.39	−1.37	0.063	0.125
	S_T3	B0T	0.523	0.232	1.05	−0.86	0.329	0.142
		R3	0.060	0.104	−1.38	−1.31	0.081	0.091
		R2	0.149	0.187	−0.50	−0.60	0.120	0.197
粉砕材混合 PP	S_V 低速	B0T	0.444	0.432	0.41	0.41	0.389	0.415
		R3	0.051	0.101	−0.92	−0.76	0.165	0.195
		R2	0.247	0.365	0.11	0.30	0.408	0.505
	S_V 高速	B0T	0.056	0.056	−1.00	−1.05	0.045	0.047
		R3	0.039	0.039	−1.82	−1.82	0.039	0.040
		R2	0.066	0.068	−1.30	−1.28	0.064	0.068
	S_T	B0T	0.016	0.014	−2.76	−2.92	0.015	0.016
		R3	0.033	0.033	−1.95	−1.94	0.041	0.042
		R2	0.063	0.066	−1.28	−1.23	0.084	0.124
	S_T3	B0T	0.178	0.208	−1.88	−1.89	0.064	0.116
		R3	0.043	0.069	−1.55	−1.50	0.080	0.088
		R2	0.166	0.231	−0.79	−0.67	0.193	0.255

表 4　B0T の T_{set} の長さスケール（S_T の学習。事後分布の要約。posterior_summary.csv）

材料	最尤推定	事後の中央値	2.5%	97.5%	R-hat
PP	0.0121	13.8	9.48	20.3	1.001
粉砕材混合 PP	30.6	33.8	13.7	86.1	1.213

表 5　results/step3c_mcmc/ の表

ファイル	中身と主な列
posterior_*.csv（12 個）	事後サンプル（対数）。chain、draw、各ハイパーパラメータ（log_c：振幅の 2 乗、log_ls_*：長さスケール、log_c_lin・log_sigma0：線形項、log_noise：ノイズ分散）、lp（対数事後密度）、accepted。
posterior_summary.csv	ハイパーパラメータごとの事後分布の要約。MLE（最尤推定値）、post_mean、median、q2.5・q97.5、r_hat、ess_bulk、ess_tail、post_at_bound（範囲の端に届いたか）。
sampler_stats.csv	組み合わせごとのサンプラーの統計（採択率、最大 R-hat、最小 ESS、端に届いた数、時間）。
chain_info.csv	チェーンごとの採択率・提案の大きさ・時間。
metrics.csv	最尤推定（MLE）と MCMC の指標（RMSE、R2、被覆率、NLPD、予測標準偏差）。split（S_V・S_T・S_T3）、subset。
mle_vs_mcmc.csv	最尤推定と MCMC の差（NLPD の差、区間の広さの比）。
tset_effect_mcmc.csv	設定温度の効果（190/230 ℃ の粘度比）の、最尤推定・事後の中央値・2.5%・97.5%、1 を超える割合。
candidates.csv	候補のモデルと、選び方。

6 結果のまとめ

6.1 観点ごとの結論

1. **収束**：12 組のうち 11 組が、R-hat 1.01 以下・ESS 400 以上を満たしました。満たさなかったのは、粉砕材混合 PP の B0T（S_T の学習）です。多峰性（複数の山）のためで、予測には 4 本のチェーンの全サンプルを使いました。
2. **B0T は、MCMC で直る**：手順 3b で、PP の S_T の B0T は、最尤推定が谷に止まり、210 ℃ を外しました（RMSE 0.362）。MCMC は、山の本体を見つけ、RMSE 0.010、NLPD −3.15 になりました（図 A、表 3）。ただし、B0T の事後分布は多峰性で、扱いにくいモデルです。
3. **R3 は、最尤推定で十分**：R3 の MCMC と最尤推定は、高速側・S_T でほぼ同じ（NLPD の差 0.1 未満）です。低速側では、MCMC の区間が約 1.2 倍広く（外挿で、広めになるのは妥当）、NLPD は +0.11（PP）・+0.16（粉砕材混合 PP）と、少し悪くなります。ハイパーパラメータが 1 つの山に決まる R3 では、1 組で近似して問題ありません。
4. **R2（設定値だけ）は、MCMC で区間が広がる**：S_T で約 1.5〜2 倍。実測の $\dot{\gamma}$ を使わない分、不確かさが大きいことを、区間が表しています。
5. **決まらないパラメータ**：線形項の σ_0 は、データで決まらず、事前の範囲いっぱいに広がります（予測にはほとんど効きません）。R3 の T_{set} の長さスケールは、上限（100）に近く、温度の効果が、ほぼ直線的（線形項）で表されています。
6. **設定温度の効果は、ハイパーパラメータによらない**：190/230 ℃ の粘度比の 95% 区間の幅は、B0T・R3 で 0.02 未満です（図 B）。
7. **結論**：基本モデル（R3）は、最尤推定でよく、MCMC は、最適化が不安定なモデル（B0T）の確認と、区間を広めに見たいときに使います。手順 5 の本実装で、MCMC を使うかは、構造（5a）が決まってから相談します。

6.2 次の手順

▷**手順 5a**：温度のシフト構造の見直しです（別の説明書）。ここで確かめた、「条件平均の $\dot{\gamma}$ を入力にした R3 は、最尤推定でも十分」という結論は、5a の評価（ショット単位の GPR の最尤推定）にも使えます。

▷**手順 5（本実装）**：5a の結果を見て決めます。最終モデルでは、MCMC を使うかを、そこでまた相談します。